

コスト価格表

実測値は 2026-08-11 計測・請求突き合わせ済み

SocraMetry は 1 回の学習セッションで LLM を 10～15 回呼びますが、**1 セッションの原価は約 5～7 円**です。本書はその実測値と、安さを支える設計、および規模別の費用感をまとめたものです。

1 セッションの原価(実測)

4.9～6.8 円

平均 6.0 円 / 0.0361 USD

1 人あたり月額原価(週 2 回利用)

39～55 円

月 8 セッション換算

実測と請求の差

6%

クレジット消費と突き合わせ検証済み

1. なぜ安いのか — モデルの出し分けがそのままコスト設計

LLM 呼び出しには性質のはっきりした偏りがあります。**難しい処理(原因の診断)**は 1 回だけ、残りの 10 回以上は速度と制約遵守だけが要る簡単な処理です。この偏りに合わせて、役割ごとにモデルを出し分けます。

Diagnoser(高品質モデル・1 回)

- focusHints(着眼点だけを渡す。結論は渡さない)
- Hinter (安価モデル)
- Questioner (安価モデル) × 8～12 回
- Judge (安価モデル)

役割	何をするか	モデル階層	回数/セッション	コスト占有率(実測)
Diagnoser	エラーから原因・着眼点を特定	高品質	1	43.0%
Revealer	最終ゲートの解説を生成	高品質	0～1	29.1%
Reporter	振り返りと学びの言語化	高品質	1	24.0%
Questioner	選択式の設問を生成	安価	8～12	3.4%
Judge	原因宣言の到達判定	安価	1～3	0.3%
Hinter	最初のヒントを生成	安価	1	0.2%

高品質モデルを使うのは「1 回しか呼ばれない場所」だけ。回数の多い設問生成は安価モデルが担うため、**設問 1 問あたりの原価は 0.043 円**。利用者が何問解いても原価はほとんど増えません。すべて高品質モデルで処理した場合と比べ、実測で **45～68% の削減**(設問数に依存)になります。

2. 1 セッションの原価(実測)

ケース	LLM 呼び出し	原価(USD)	原価(円)
最初のゲートで自力解決	4 回	0.0295	約 4.9 円
実測 3 セッションの平均	—	0.0361	約 6.0 円
最終ゲートまで到達(全 5 段階出題)	10 回	0.0414	約 6.8 円

円換算は 1 USD = 165 円(直近 2 か月の実勢 155～162 円の上限より上に固定。見積もりの誤差を「実際より高く見積もる」安全側に倒しています)。金額は内部推定を実際のクレジット消費と突き合わせ、差 6% であることを確認済みです。

3. 規模別の月額原価

利用規模	セッション/月	月額原価(下限～上限)
個人(週 2 回)	8	39～55 円
小チーム 10 名(週 2 回)	80	390～550 円
100 名(週 2 回)	800	3,900～5,500 円

原価は「セッションを何回開始したか」でほぼ決まります。1 セッションの中で利用者がどれだけ深く考え、何問解いても、原価はほとんど動きません (設問 100 問でも +4.3 円)。製品の価値が出る「深く使う」ほど原価効率が上がる構造です。

4. 参考価格と粗利構造

※ 販売価格は検討中です。以下はライセンスを 1,000 円/人月と仮定した場合の試算であり、正式な提供価格ではありません。

利用頻度	月間セッション	原価(上限で計算)	粗利率
週 2 回(想定利用)	8	55 円	94.5%
週 5 回	20	137 円	86.3%
1 日 2 回	40	273 円	72.7%
損益分岐	146	1,000 円	0%

損益分岐は 1 人あたり月 146 セッション(営業日で約 7 回/日)。想定利用(週 2 回)の 18 倍にあたり、現実的な利用でここに達することはありません。さらにレート制限(10 セッション/時/メンバー)とセッションあたりのトークン上限が、コストの上振れを構造的に防いでいます。

5. コスト管理の仕組み

仕組み	内容
単価ログ	すべての LLM 呼び出しを 1 リクエスト単位で記録(モデル・トークン数・推定コスト)。セッション完了時に役割別の内訳サマリを出力
請求との突き合わせ	内部推定と実際のクレジット消費を照合済み(差 6%)。推定値ではなく検証済みの数字で語れる
セッション上限	1 セッション 80,000 トークンで打ち切り。1 人のユーザーが無制限に課金を発生させられない
レート制限	セッション作成は 10 回/時/メンバー。原価はセッション開始回数に比例するため、これがそのまま価格の防波堤になる
出力上限 (max_tokens)	役割ごとに「必要な長さ」から上限を設定。実測の 1.5 倍以上の余裕を持たせつつ、暴走的な生成を防ぐ